

Multimodal Driver Stress Recognition

Replica parziale di *Multimodal Car Driver Stress Recognition*
Bianco, Napoletano, Schettini – PervasiveHealth 2019

Francesco Girlanda

Giugno 2026

Indice

1	Introduzione	2
2	Dataset	2
2.1	Origine e versione utilizzata	2
2.2	Sessioni sperimentali	2
3	Pipeline di elaborazione	3
3.1	Step 1 – Preprocessing	3
3.2	Step 2 – Segmentazione e Feature Extraction	3
3.3	Step 3 – Classificazione	4
4	Risultati	4
5	Conclusioni	5
6	Semplificazioni e differenze rispetto al paper	6

Introduzione

Il presente documento descrive la replica parziale del lavoro di ricerca:

Simone Bianco, Paolo Napoletano, Raimondo Schettini, *Multimodal Car Driver Stress Recognition*, PervasiveHealth 2019.

Il paper propone un sistema di riconoscimento dello stress del conducente basato su segnali fisiologici acquisiti durante sessioni di guida simulata. Il problema è formulato come **classificazione binaria** tra condizioni di stress e non-stress, affrontato con tecniche di machine learning.

La replica si concentra sulle seguenti fasi della pipeline originale:

- preprocessing e pulizia del dataset;
- segmentazione temporale dei segnali;
- estrazione delle feature;
- classificazione tramite kNN e SVM con validazione incrociata.

Non sono state implementate le componenti più avanzate del paper: reti neurali artificiali (ANN) e classificatori ensemble (Stacking).

Dataset

Origine e versione utilizzata

È stata utilizzata la versione riformattata del dataset originale, **R-Friendly Study Data**, che contiene gli stessi dati fisiologici in un formato più facilmente elaborabile.

Sessioni sperimentali

Il paper originale cita le seguenti 7 sessioni:

Indice	Etichetta	Descrizione
–	B	Baseline (esclusa)
2	PD	Practice Drive
3	RD	Relaxing Drive
4	LD	Loaded Drive
5	CD	Cognitive Drive
6	ED	Emotional Drive
7	MD	Motor Drive

Tabella 1: Mapping sessioni sperimentali adottato nella replica.

La sessione Baseline è esclusa dallo studio. Nella versione del dataset scaricata era presente anche una sessione aggiuntiva (sessione 8), rimossa per questo progetto. Nel dataset originale, le sessioni da LD a MD sono randomizzate per soggetto; nella versione R-Friendly non è chiaro se l'ordine resti casuale oppure se sia fisso, pertanto è stata adottata la corrispondenza fissa indicata in tabella.

Pipeline di elaborazione

Step 1 – Preprocessing

Il preprocessing include le seguenti operazioni, nell'ordine:

1. Eliminazione delle colonne non incluse nella classificazione (dati di guida e eye tracking).
2. Rimozione dei soggetti con dati mancanti o con flag di errore nella colonna **Failure**. Il numero di soggetti si riduce da **68 a 53**.
3. Gestione dei valori fuori range come indicato nel paper.

Range di validità dei segnali

Sono state applicate le soglie riportate nell'articolo:

Segnale	Min	Max
Heart Rate	40	120
Breathing Rate	4	40
Palm EDA	28	628

Tabella 2: Range di validità per la gestione degli outlier.

Per ciascuna sessione di ogni soggetto:

- se più del **30%** dei campioni è fuori range $\Rightarrow$ la sessione viene eliminata;
- altrimenti, i valori anomali sono sostituiti con la **media dei campioni validi** dello stesso segnale.

Al termine del preprocessing rimangono **33 soggetti**.

Step 2 – Segmentazione e Feature Extraction

Segmentazione temporale

I segnali sono segmentati con i parametri indicati nel paper:

- finestra: **60 secondi**;
- overlap: **50%** (avanzamento di 30 s).

Feature estratte

Per ciascun segmento sono state estratte **20 feature** (il paper ne utilizza 21; è stata omessa la feature relativa agli intervalli RR con differenza >50 ms per impossibilità di calcolo con la precisione temporale del dataset disponibile).

Il dataset risultante è salvato in `data/full_set/full_set.csv`.

Step 3 – Classificazione

Pulizia finale

Prima della classificazione vengono gestiti i valori NaN:

- Le osservazioni con NaN nelle feature `four_moment`, `five_moment`, `kurtosis`, `skew` risultano in numero inferiore allo 0.15% dei dati totali (94/15120), pertanto vengono **eliminate**.
- I NaN nelle feature `rmsd` e `intervals_std` vengono **imputati con la media**. In una prima fase è stato introdotto data leakage, ma su proprietà relativamente stabili tra soggetti (pertanto i valori non variano molto tra training e test set). In una seconda fase l'imputazione è stata spostata all'interno dei singoli fold.
- Oltre ai segnali singoli è stato creato anche un dataset di segnali concatenati, in accordo con il paper.
- come modifica personale è stata introdotta una concatenazione parziale, solo di HR e BR, al posto di prendere tutti i segnali

Normalizzazione

Viene applicata una normalizzazione **Min-Max** calcolata esclusivamente sul training set di ciascun fold, per evitare data leakage.

Classificatori

k-Nearest Neighbors (kNN) $k = 1$, distanza euclidea.

Support Vector Machine (SVM) kernel RBF, parametri di default di scikit-learn.

Validazione

È stata utilizzata una **Stratified 5-Fold Cross Validation**.

Successivamente è stato usato il protocollo Leave-One-Subject-Out (LOSO).

Nota: per segnali concatenati è stata usato solo il protocollo LOSO

Risultati

Le accuratze ottenute sono confrontate con i risultati pubblicati nel paper per la classificazione dei singoli segnali fisiologici.

Segnale	kNN Paper	kNN Replica	SVM Paper	SVM Replica
P-EDA	53.88%	51.17%	54.31%	56.45%
HR	58.72%	50.22%	56.87%	56.09%
BR	55.97%	53.80%	62.39%	62.55%
PER-EDA	54.54%	53.78%	61.42%	59.12%

Tabella 3: Confronto tra i risultati del paper e quelli della replica per i singoli segnali.

I risultati mostrano una **buona coerenza generale** con il paper. Gli scostamenti (il più rilevante nel kNN su HR, -8.50 punti percentuali) sono coerenti con le semplificazioni adottate, elencate di seguito.

Per quanto riguarda la classificazione con feature concatenate di tutti i segnali, i risultati della replica si discostano significativamente da quelli originali. La Tabella 4 riassume i tre tentativi effettuati.

Tentativo	Segnale	kNN Paper	kNN Replica	SVM Paper	SVM Replica
1°	ALL	74.51%	53.62%	74.37%	61.40%
2°	ALL	74.51%	88.00%	74.37%	99.90%
3°	ALL	74.51%	83.50%	74.37%	99.80%

Tabella 4: Confronto tra i risultati del paper e quelli della replica per la classificazione con feature concatenate.

Le cause dei progressivi scostamenti sono analizzate nella Sezione 5.

Conclusioni

La replica realizzata riproduce correttamente le principali fasi di preprocessing, segmentazione ed estrazione delle feature descritte nell’articolo. I risultati ottenuti per i singoli segnali fisiologici presentano uno scostamento contenuto rispetto a quelli pubblicati dagli autori, coerente con le semplificazioni metodologiche adottate e con l’utilizzo di una versione differente del dataset. Lo scostamento aumenta sensibilmente nella classificazione con feature concatenate, per ragioni riconducibili a tre fattori distinti.

Nel **primo tentativo**, la mancata gestione dell’identificatore di sessione durante l’estrazione delle feature ha prodotto valori NaN in corrispondenza del disallineamento delle finestre; la successiva eliminazione di tali righe ha ridotto e sbilanciato il dataset, deteriorando le performance del modello.

Nel **secondo tentativo**, le finestre risultano correttamente allineate, ma l’imputazione dei valori NaN è stata operata sull’intero dataset prima della cross-validation, introducendo data leakage. Tale leakage, trascurabile nella classificazione per segnale singolo, diventa rilevante nella versione concatenata a causa dell’aumento dello spazio delle feature, ed è probabilmente responsabile dei risultati artificialmente elevati (SVM: 99.90%).

Nel **terzo tentativo**, l’imputazione è stata correttamente spostata all’interno di ogni fold, eliminando il leakage. I risultati rimangono comunque superiori a quelli del paper; le cause più probabili sono il numero inferiore di soggetti post-pulizia (33 vs. 37), la mancata implementazione della ventunesima feature, o imprecisioni residue nella fase di estrazione delle feature.

Semplificazioni e differenze rispetto al paper

Aspetto	Paper originale	Replica realizzata
Dataset	Dataset originale dello studio di Taamneh et al.	Versione riformattata <i>R-Friendly Study Data</i> , più accessibile.
Numero di soggetti	37 soggetti dopo la fase di pulizia	33 soggetti dopo la fase di pulizia
Numero di feature	21 feature per finestra temporale	20 feature per finestra. È stata omessa una feature basata sulla differenza tra intervalli di picco superiori a 50 ms.
Classificatori	kNN, SVM, ANN e classificatore ensemble (stacking)	Implementati soltanto kNN e SVM.
Ottimizzazione SVM	Ricerca degli iperparametri tramite Grid Search	Utilizzati i parametri di default della libreria Scikit-Learn.
ANN	Rete neurale shallow con ottimizzazione degli iperparametri	Non implementata.
Stacking Classifier	Combinazione di kNN, SVM e ANN mediante majority voting	Non implementato.

Tabella 5: Principali differenze tra il lavoro originale e la replica realizzata.

Progetto sviluppato esclusivamente per finalità didattiche e di ricerca universitaria.