

# Multimodal Driver Stress Recognition

Replica parziale di *Multimodal Car Driver Stress Recognition*  
Bianco, Napoletano, Schettini – PervasiveHealth 2019

Francesco Girlanda

Giugno 2026

## Indice

---

|          |                                                       |          |
|----------|-------------------------------------------------------|----------|
| <b>1</b> | <b>Introduzione</b>                                   | <b>2</b> |
| <b>2</b> | <b>Dataset</b>                                        | <b>2</b> |
| 2.1      | Origine e versione utilizzata . . . . .               | 2        |
| 2.2      | Sessioni sperimentali . . . . .                       | 2        |
| <b>3</b> | <b>Pipeline di elaborazione</b>                       | <b>3</b> |
| 3.1      | Step 1 – Preprocessing . . . . .                      | 3        |
| 3.2      | Step 2 – Segmentazione e Feature Extraction . . . . . | 3        |
| 3.3      | Step 3 – Classificazione . . . . .                    | 4        |
| <b>4</b> | <b>Risultati</b>                                      | <b>4</b> |
| <b>5</b> | <b>Semplificazioni e differenze rispetto al paper</b> | <b>5</b> |
| <b>6</b> | <b>Conclusioni</b>                                    | <b>5</b> |

## Introduzione

---

Il presente documento descrive la replica parziale del lavoro di ricerca:

Simone Bianco, Paolo Napoletano, Raimondo Schettini, *Multimodal Car Driver Stress Recognition*, PervasiveHealth 2019.

Il paper propone un sistema di riconoscimento dello stress del conducente basato su segnali fisiologici acquisiti durante sessioni di guida simulata. Il problema è formulato come **classificazione binaria** tra condizioni di stress e non-stress, affrontato con tecniche di machine learning.

La replica si concentra sulle seguenti fasi della pipeline originale:

- preprocessing e pulizia del dataset;
- segmentazione temporale dei segnali;
- estrazione delle feature;
- classificazione tramite kNN e SVM con validazione incrociata.

Non sono state implementate le componenti più avanzate del paper: reti neurali artificiali (ANN), classificatori ensemble (Stacking), fusione multimodale delle feature e la validazione Leave-One-Subject-Out (LOSO).

## Dataset

---

### Origine e versione utilizzata

È stata utilizzata la versione riformattata del dataset originale, **R-Friendly Study Data**, che contiene gli stessi dati fisiologici in un formato più facilmente elaborabile.

### Sessioni sperimentali

Il paper originale cita le seguenti 7 sessioni:

| Indice | Etichetta | Descrizione        |
|--------|-----------|--------------------|
| –      | B         | Baseline (esclusa) |
| 2      | PD        | Practice Drive     |
| 3      | RD        | Relaxing Drive     |
| 4      | LD        | Loaded Drive       |
| 5      | CD        | Cognitive Drive    |
| 6      | ED        | Emotional Drive    |
| 7      | MD        | Motor Drive        |

Tabella 1: Mapping sessioni sperimentali adottato nella replica.

La sessione Baseline è esclusa dallo studio. Nella versione del dataset scaricata era presente anche una sessione aggiuntiva (sessione 8), rimossa per questo progetto. Nel dataset originale, le sessioni da LD a MD sono randomizzate per soggetto; nella versione R-Friendly non è chiaro se l'ordine resti casuale oppure se sia fisso, pertanto è stata adottata la corrispondenza fissa indicata in tabella.

## Pipeline di elaborazione

---

### Step 1 – Preprocessing

Il preprocessing include le seguenti operazioni, nell'ordine:

1. Eliminazione delle colonne non incluse nella classificazione (dati di guida e eye tracking).
2. Rimozione dei soggetti con dati mancanti o con flag di errore nella colonna **Failure**. Il numero di soggetti si riduce da **68 a 53**.
3. Gestione dei valori fuori range come indicato nel paper.

### Range di validità dei segnali

Sono state applicate le soglie riportate nell'articolo:

| Segnale        | Min | Max |
|----------------|-----|-----|
| Heart Rate     | 40  | 120 |
| Breathing Rate | 4   | 40  |
| Palm EDA       | 28  | 628 |

Tabella 2: Range di validità per la gestione degli outlier.

Per ciascuna sessione di ogni soggetto:

- se più del **30%** dei campioni è fuori range  $\Rightarrow$  la sessione viene eliminata;
- altrimenti, i valori anomali sono sostituiti con la **media dei campioni validi** dello stesso segnale.

Al termine del preprocessing rimangono **33 soggetti**.

### Step 2 – Segmentazione e Feature Extraction

#### Segmentazione temporale

I segnali sono segmentati con i parametri indicati nel paper:

- finestra: **60 secondi**;
- overlap: **50%** (avanzamento di 30 s).

#### Feature estratte

Per ciascun segmento sono state estratte **20 feature** (il paper ne utilizza 21; è stata omessa la feature relativa agli intervalli RR con differenza  $>50$  ms per impossibilità di calcolo con la precisione temporale del dataset disponibile).

Il dataset risultante è salvato in `data/full_set/full_set.csv`.

## Step 3 – Classificazione

### Pulizia finale

Prima della classificazione vengono gestiti i valori NaN:

- Le osservazioni con NaN nelle feature `four_moment`, `five_moment`, `kurtosis`, `skew` risultano in numero inferiore allo 0.15% dei dati totali (94/15120), pertanto vengono **eliminate**.
- I NaN nelle feature `rmsd` e `intervals_std` vengono **imputati con la media**. Si introduce quindi data leakage, ma su proprietà relativamente stabili tra soggetti (pertanto i valori non variano molto tra training e test set)

### Normalizzazione

Viene applicata una normalizzazione **Min-Max** calcolata esclusivamente sul training set di ciascun fold, per evitare data leakage.

### Classificatori

**k-Nearest Neighbors (kNN)**  $k = 1$ , distanza euclidea.

**Support Vector Machine (SVM)** kernel RBF, parametri di default di scikit-learn.

### Validazione

È stata utilizzata una **Stratified 5-Fold Cross Validation**.

Il protocollo Leave-One-Subject-Out (LOSO) del paper non è stato implementato.

## Risultati

Le accuratze ottenute sono confrontate con i risultati pubblicati nel paper per la classificazione dei singoli segnali fisiologici.

| Segnale | kNN Paper | kNN Replica | SVM Paper | SVM Replica |
|---------|-----------|-------------|-----------|-------------|
| P-EDA   | 53.88%    | 51.15%      | 54.31%    | 56.37%      |
| HR      | 58.72%    | 50.43%      | 56.87%    | 56.09%      |
| BR      | 55.97%    | 53.58%      | 62.39%    | 63.00%      |
| PER-EDA | 54.54%    | 53.65%      | 61.42%    | 58.91%      |

Tabella 3: Confronto tra i risultati del paper e quelli della replica.

I risultati mostrano una **buona coerenza generale** con il paper. Gli scostamenti (il più rilevante nel kNN su HR,  $-8.29$  punti percentuali), sono coerenti con le semplificazioni adottate, elencate di seguito.

## Semplificazioni e differenze rispetto al paper

---

| Aspetto                | Paper originale                                                                                           | Replica realizzata                                                                                                     |
|------------------------|-----------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| Dataset                | Dataset originale dello studio di Taamneh et al.                                                          | Versione riformattata <i>R-Friendly Study Data</i> , più accessibile.                                                  |
| Numero di soggetti     | 37 soggetti dopo la fase di pulizia                                                                       | 33 soggetti dopo la fase di pulizia                                                                                    |
| Numero di feature      | 21 feature per finestra temporale                                                                         | 20 feature per finestra. È stata omessa una feature basata sulla differenza tra intervalli di picco superiori a 50 ms. |
| Classificatori         | kNN, SVM, ANN e classificatore ensemble (stacking)                                                        | Implementati soltanto kNN e SVM.                                                                                       |
| Concatenazione segnali | Valutazione sia dei singoli segnali sia della concatenazione delle feature provenienti da tutti i segnali | Analizzati esclusivamente i singoli segnali fisiologici                                                                |
| Validazione            | 5-Fold Cross Validation e Leave-One-Subject-Out (LOSO)                                                    | Implementata soltanto la Stratified 5-Fold Cross Validation.                                                           |
| Ottimizzazione SVM     | Ricerca degli iperparametri tramite Grid Search                                                           | Utilizzati i parametri di default della libreria Scikit-Learn.                                                         |
| ANN                    | Rete neurale shallow con ottimizzazione degli iperparametri                                               | Non implementata.                                                                                                      |
| Stacking Classifier    | Combinazione di kNN, SVM e ANN mediante majority voting                                                   | Non implementato.                                                                                                      |

Tabella 4: Principali differenze tra il lavoro originale e la replica realizzata.

## Conclusioni

---

La replica realizzata riproduce correttamente le principali fasi della pipeline descritta nel paper: preprocessing, segmentazione, estrazione delle feature e classificazione con kNN e SVM.

I risultati sono coerenti con le semplificazioni metodologiche adottate e con l'utilizzo di una versione differente del dataset. Il margine di errore rispetto ai valori pubblicati è contenuto, in particolare per SVM su BR e PER-EDA dove la replica supera leggermente il paper.

Lavori futuri potrebbero includere l'implementazione della concatenazione delle feature, la validazione LOSO e la ricerca automatica degli iperparametri SVM, per avvicinarsi ulteriormente ai risultati completi riportati nell'articolo originale. Inoltre c'è la possibilità di utilizzare la stessa pipeline su nuovi dataset simili più grandi.

*Progetto sviluppato esclusivamente per finalità didattiche e di ricerca universitaria.*